

CodeReview-New 기반 Review-to-Repair에서 위치 정보의 역할 진단

Diagnosing the Role of Location Information in Review-to-Repair Using CodeReview-New

요 약

본 연구는 Review-to-Repair에서 리뷰 코멘트가 주어진 상태에 정답 위치 마커를 추가했을 때, 위치 중첩 증가가 exact match 기준의 정확 수정 증가로 이어지는지 진단한다. CodeReview-New 100개 예제와 qwen2.5-coder:7b를 사용해 no_review, direct, gold_location 세 조건을 비교하였다. direct는 no_review 대비 exact_match_line_trim을 0.00에서 0.07로 높였고, gold_location은 location_overlap_f1을 0.578에서 0.740으로 높였다. 그러나 gold_location의 direct 대비 exact gain은 +0.020에 그쳤고 95% 신뢰구간은 0을 포함하였다. 이는 정답 위치 정보가 위치 중첩에는 기여하지만 최종 정확 수정으로 충분히 전환되지 않을 수 있음을 보여준다.

1. 서론

코드 리뷰 환경에서는 개발자가 자연어 리뷰 코멘트를 바탕으로 코드를 수정하고 재수정하는 과정이 반복된다. 최근 대규모 언어모델(Large Language Model, LLM)을 활용한 자동 코드 수정 연구는 이러한 과정을 자동화하려 하지만, 모델이 실패했을 때 그 원인이 무엇인지는 명확히 분리되지 않는 경우가 많다. 특히 Review-to-Repair에서는 실패 원인이 리뷰 의미 이해(review understanding), 수정 위치 파악(change localisation), 실제 코드 편집 생성(edit generation) 중 어느 단계에 있는지를 구분하는 것이 중요하다. 기존 코드 리뷰 자동화 및 자동 프로그램 수리 연구는 주로 end-to-end 성능(end-to-end performance, 입력부터 최종 수정 성공까지 한 번에 평가하는 방식)에 초점을 두었다. 그러나 최종 정답 코드와 거의 동일할지 보는 엄격한 지표(exact match)가 낮게 나왔을 때, 그 실패가 리뷰를 이해하지 못해서인지, 고칠 위치를 찾지 못해서인지, 아니면 위치를 알아도 올바른 편집을 만들지 못해서인지는 별도로 드러나지 않는다. 본 연구의 핵심 질문은 “리뷰 코멘트가 주어진 상태에서 정답 위치 마커를 추가하면, 위치 중첩 증가는 exact match 기준의 정확 수정 증가로 이어지는가?”이다. no_review는 리뷰 없이 코드만 제공하는 조건이고, direct는 코드와 리뷰 코멘트를 함께 제공하는 조건이다. gold_location은 direct에 정답 변경 위치 마커를 추가한 정답 정보를 일부 제공해 진단하는 조건(oracle condition)이다. 단, gold_location은 실제 배포 가능한 설정이 아니며, 위치 정보가 주어졌을 때도 남은 병목을 확인하기 위한 진단 조건으로 해석한다. 본 논문의 기여는 세 가지다. 첫째, Review-to-Repair 실패 요인을 3 조건으로 분해해 읽는 진단 프로토콜을 제시한다. 둘째, CodeReview-New 100개 예제와 qwen2.5-coder:7b를 사용해 리뷰 코멘트 제공과 정답 위치 정보 주입의 효과를 비교한다. 셋째, 정답 위치 정보가

location_overlap_f1을 높이더라도 exact match 성공으로 충분히 전환되지 않을 수 있음을 보인다.

2. 관련연구

코드 리뷰 자동화 연구는 리뷰 코멘트 생성, 리뷰 기반 코드 변경, 코드 정제 등 다양한 태스크를 다루어 왔다. Tufano et al.[1,2]은 코드 리뷰 데이터를 활용하여 리뷰 코멘트 기반 코드 변경과 코드 정제의 자동화 가능성을 탐색하였다. Li et al.[3]은 CodeReviewer를 통해 리뷰 코멘트 생성, 수정 품질 평가, 코드 정제를 통합한 사전학습 기반 접근을 제안하였다. Review4Repair[4]는 코드 리뷰 코멘트를 자동 프로그램 수리 과정에 직접 활용했다는 점에서 본 연구와 가장 가깝다. 또한 LLM 기반 자동 프로그램 수리 연구[5]는 대규모 언어모델이 코드 수정에 활용될 수 있음을 보였다. 그러나 본 연구는 새로운 repair system(수리 시스템)을 제안하지 않고, Review-to-Repair 실패를 review understanding, change localisation, edit generation의 관점에서 분해해 읽는 진단 연구라는 점에서 차이가 있다.

3. 본론

본 연구는 새로운 수리 모델을 제안하는 것이 아니라, 동일한 예제 집합에서 입력 정보만 달리하는 3조건 진단 프로토콜을 사용한다. no_review는 리뷰 코멘트 없이 코드만 제공하는 조건이고, direct는 코드와 리뷰 코멘트를 함께 제공하는 조건이다. gold_location은 direct에 정답 변경 위치 마커를 추가한 oracle condition이다. gold_location은 실제 배포 환경이나 위치 정보의 이론적 상한을 의미하지 않으며, 정답 위치 정보가 주어졌을 때도 남은 실패를 보기 위한 진단 조건이다. 표 1은 세 조건의 입력 구성과 진단 목적을 정리한 것이다.

표 1. 세 조건의 입력 구성

조건	제공 입력	진단 목적
no_review	코드	리뷰 없는 기본 조건
direct	코드 + 리뷰 코멘트	리뷰 코멘트 제공 효과 관찰
gold_location	코드 + 리뷰 코멘트 + 정답 위치 마커	정답 위치 정보 주입 효과 관찰

그림 1은 본 연구의 3조건 진단 프로토콜을 요약한다. 세 조건은 동일한 CodeReview-New 예제를 사용하며, 모델에 제공되는 입력 정보만 다르다. 이를 통해 리뷰 코멘트 제공 효과와 정답 위치 정보 주입 효과를 분리해서 관찰한다.




그림 1. Review-to-Repair 3조건 진단 프로토콜

연구 질문은 다음과 같다. RQ1은 리뷰 코멘트가 no_review 대비 exact match 기준 수정 성공률에 어떤 차이를 보이는지 묻는다. RQ2는 gold_location이 within-snippet 중첩 및 exact match를 변화시키는지 확인한다. RQ3은 위치 중첩 증가가 정확 수정 향상으로 이어지는지 묻는다. 본 논문은 100개 예제 기반의 파일럿 진단 연구이므로, 위치 정보 주입 이후의 세부 오류 유형 분류는 후속 연구로 남긴다.

4. 실험

4.1 실험 요약

실험 대상은 CodeReview-New이며, 데이터 단위는 파일 전체가 아니라 코드 스니펫 혹은 hunk이다. 각 예제는 수정 전 코드(old), 리뷰 코멘트(review), 정답 코드(new)를 포함한다. 따라서 본 연구의 수정 위치 파악(change localisation) 해석 범위는 full-file localisation(파일 전체에서 수정 위치를 찾는 문제)이 아니라 within-snippet localisation(스니펫 내부에서 수정 위치를 보는 문제)으로 제한된다.

본 실험에서는 seed=42로 구성된 CodeReview-New 100개 예제를 사용하였다. 모델은 qwen2.5-coder:7b이며, Ollama 백엔드에서 temperature=0.0으로 실행하였다. 비교 조건은 no_review, direct, gold_location의 세 가지이며, 각 조건은 동일한 100개 예제에 적용되었다. 따라서 총 생성 수는 300개 출력(100 examples × 3 conditions)이다. 실험 결과, 무결성 점검에서 중복 0건, 누락 0건, 오류 로그 0건이 확인되었다.

gold_location 조건에서는 정답 diff로부터 변경 대상 라인을 식별하고, 해당 위치를 입력 스니펫 안에 마커로 표시하여 모델에 제공하였다. 단, gold_location은 실제 배포 환경을 가정한 조건이 아니라, 정답 위치 정보가 주어졌을 때도 남는 실패를 확인하기 위한 정답 정보를 일부 제공해 진단하는 조건(oracle condition)으로 해석한다.

4.2 실험 평가 척도 및 베이스라인

정확 수정 성능은 exact_match_line_trim으로 측정하였다. exact match는 모델 출력이 정답 코드와 줄 단위로 일치하는지를 본다. 위치 중첩은 location_overlap_f1로 측정하였다. location_overlap_f1은 모델이 변경 위치를 독립적으로 예측했는지를 직접 측정하는 지표가 아니라, old 대비 모델 출력에서 변경된 라인 집합과 old 대비 정답 new에서 변경된 라인 집합 사이의 사후 F1 중첩이다. 따라서 이 지표는 독립적인 위치 예측 정확도라기보다, 출력 변경 라인과 정답 변경 라인의 within-snippet 중첩을 보는 진단 지표로 해석한다.

비교 조건은 no_review, direct, gold_location이다. no_review는 리뷰 없는 기본 조건이고, direct는 리뷰 코멘트를 제공하는 조건이며, gold_location은 정답 변경 위치 마커를 추가로 제공하는 oracle condition이다. 조건 간 차이는 paired bootstrap confidence interval로 제시한다.

4.3 실험 결과

표 2. 메인 결과

조건	exact_match_line_trim	location_overlap_f1
no_review	0.00	0.524
direct	0.07	0.578
gold_location	0.09	0.740

표 3. Bootstrap Gain 요약

비교	지표	Gain	95% CI
direct - no_review	Exact	+0.070	[0.020, 0.120]
direct - no_review	Loc.F1	+0.054	[-0.016, 0.123]
gold_location - direct	Exact	+0.020	[-0.050, 0.090]
gold_location - direct	Loc.F1	+0.162	[0.089, 0.235]

표 2와 표 3은 위치 정보 주입이 위치 중첩과 정확 수정에 서로 다르게 작용함을 보여준다. 표 2에서 gold_location은 direct보다 location_overlap_f1을 0.578에서 0.740으로 크게 높였지만, exact_match_line_trim은 0.07에서 0.09로 제한적으로만 증가하였다. gold_location - direct의 Loc.F1 gain은 +0.162이고 95% 신뢰구간이 0을 포함하지 않지만, Exact gain은 +0.020이며 95% 신뢰구간이 0을 포함한다. 따라서 정답 위치 마커는 변경 위치 중첩을 높이는 데에는 효과가 있었지만, 그 효과가 exact match 기준의 정확 수정 성공으로 안정적으로 전환되었다고 보기는 어렵다.




그림 2. 정확 수정률과 위치 중첩 성능의 조건별 변화

RQ1. direct 조건은 no_review보다 exact_match_line_trim이 높았다. no_review는 0.00인 반면 direct는 0.07이었고, direct - no_review의 exact gain은 +0.070, 95% CI [0.020, 0.120]이었다. 이는 본 표본에서 리뷰 코멘트가 일부 사례의 정확 수정에 도움을 줄 수 있다는 초기 근거로 해석할 수 있다.

RQ2. gold_location 조건은 location_overlap_f1을 direct의 0.578에서 0.740으로 높였다. gold_location - direct의 Loc.F1 gain은 +0.162, 95% CI [0.089, 0.235]로 0을 포함하지 않았다. 그러나 exact_match_line_trim은 direct 0.07에서 gold_location 0.09로 소폭 증가했고, exact gain의 95% CI [-0.050, 0.090]은 0을 포함하였다. 따라서 정답 위치 정보 주입은 위치 중첩을 높였지만 direct 대비 정확 수정률 향상을 명확히 보였다고 말하기는 어렵다.

RQ3. 위치 중첩 증가는 exact match 기준의 정확 수정 증가로 안정적으로 전환되지 않았다. RQ2에서 확인한 것처럼 gold_location은 위치 중첩을 크게 높였지만, Exact gain의 95% 신뢰구간은 0을 포함하였다. 따라서 본 표본에서는 정답 위치 정보가 변경 위치를 정답 위치에 가깝게 만들었더라도, 최종 정확 수정 성공으로 충분히 이어졌다고 보기는 어렵다. 이는 Review-to-Repair 실패를 위치 파악만으로 설명하기 어렵고, 리뷰 의미 반영과 실제 코드 편집 생성 단계도 함께 고려해야 함을 보여준다.

5. 토 의

본 연구의 핵심 관찰은 “위치 파악은 관련 요인이지만 충분조건은 아니다”라는 점이다. qwen2.5-coder:7b 실험에서 gold_location은 location_overlap_f1을 0.578에서 0.740으로 높였다. 이는 정답 위치 마커가 모델 출력의 변경 라인을 정답 변경 라인 쪽으로 이동시키는 데 도움을 줄 수 있음을 의미한다. 그러나 exact_match_line_trim은 direct 0.07에서 gold_location 0.09로 제한적으로만 증가했고, direct 대비 exact gain의 95% CI는 0을 포함하였다. 따라서 정답 위치 정보가 제공되더라도 최종 정확 수정이 충분히 보장된다고 보기는 어렵다.

이 결과는 Review-to-Repair를 단일 end-to-end 성능만으로 평가할 때 생길 수 있는 해석의 한계를 보여준다. 낮은 exact match는 위치 파악 실패만을 의미하지 않을 수 있으며, 리뷰 의미

반영, 실제 편집 생성, 그리고 exact match 평가의 보수성이 함께 영향을 줄 수 있다. 다만 본 연구는 잔여 실패 유형을 수작업으로 라벨링하지 않았으므로, 어떤 오류 유형이 주된 원인인지는 결론짓지 않는다. 후속 연구에서는 오류 유형 라벨링과 의미 기반 또는 실행 기반 평가를 추가해 위치 정보 주입 이후에도 남은 실패를 더 구체적으로 분석할 필요가 있다.

6. 결 과

본 연구는 Review-to-Repair에서 정답 위치 마커가 위치 중첩 증가를 정확 수정 증가로 전환하는지 확인하기 위해 no_review, direct, gold_location의 3조건 비교를 수행하였다. CodeReview-New 100개 예제와 qwen2.5-coder:7b를 사용한 결과, direct는 no_review 대비 exact_match_line_trim을 0.00에서 0.07로 높였고, gold_location은 location_overlap_f1을 0.578에서 0.740으로 높였다. 그러나 gold_location - direct의 exact gain은 +0.020에 그쳤으며, 95% bootstrap confidence interval도 [-0.050, 0.090]으로 0을 포함하였다.

이 결과는 리뷰 코멘트가 일부 정확 수정에 도움을 줄 수 있고, 정답 위치 정보가 위치 중첩을 높일 수 있음을 보여준다. 그러나 본 실험 범위에서는 위치 중첩 증가가 exact match 기준의 최종 수정 성공으로 안정적으로 전환되었다고 보기는 어렵다. 따라서 Review-to-Repair 실패를 위치 파악 문제만으로 해석하기는 어렵고, review understanding과 edit generation 단계도 함께 고려해야 한다. 다만 본 연구는 100개 서브셋과 단일 모델에 기반한 파일럿이므로, 후속 연구에서는 더 큰 표본, 다양한 코드 LLM, predicted_location 조건, 오류 라벨링 및 의미 기반 또는 실행 기반 평가를 추가할 필요가 있다.

참고문헌

- [1] M. Tufano, C. Watson, G. Bavota, M. Di Penta, M. White, and D. Poshyvanyk, "Towards Automating Code Review Activities," Proc. ICSE 2021, pp. 163-174, 2021.
- [2] M. Tufano, D. Drain, A. Svyatkovskiy, S. K. Deng, and N. Sundaresan, "Using Pre-Trained Models to Boost Code Review Automation," Proc. ICSE 2022, pp. 1-13, 2022.
- [3] Z. Li, S. Lu, S. Guo, N. Duan, S. Jannu, G. Jenks, D. Majumder, J. Green, A. Svyatkovskiy, S. Fu, and N. Sundaresan, "Automating Code Review Activities by Large-Scale Pre-Training," Proc. FSE 2022, pp. 1035-1047, 2022.
- [4] F. Huq, M. Hasan, Md. M. A. Haque, S. Mahbub, A. Iqbal, and T. Ahmed, "Review4Repair: Code review aided automatic program repairing," Information and Software Technology, vol. 143, art. no. 106765, 2022.
- [5] W. Jiang, F. Shi, D. Lu, Y. Liu, H. Wang, Q. Chen, and T. Liu, "Impact of Code Language Models on Automated Program Repair," Proc. ICSE 2023, pp. 1430-1442, 2023